


**\*\*Prompt Engineering:**

## Prompt Engineering




Как се случва интеракцията между потребителя и AI Modela.

Обикновено се изпраща някакъв промпт и AI Modela връща отговор.

Все едно викаме Web API, само че по друг начин. Идеята е променяме малко този промпт така че да включим повече инф в него, така че да дадем по-добри насоки на AI Modela и очакването е че AI Modela ще ни върне по-добър Response

---

**\*\*CAG:**




Взимаме промпта на потребителя (въпрос например) - обоготяваме го дали ще е в системният промпт или в user prompt-а важното е да се случи това обоготяване -> добавяме тази инф в системния промпт например и така се обръщаме към ai modela, който ще има налична цялата информация, цялото познание за да може да върне по точен response. Става неприложима когато External Knowledge стане твърде голяма.

**\*\*RAG (Retrieval-Augmented Generation)**

- не се наместваме посредата между потребителя и ai modela. даваме възможност потребителя неговият въпрос да достигне ai


modela. промпта достига ai modela и той връща респонс. (прилича на prompt engineering, но не е ) Това което правим - даваме на ai modela инструменти с които може да достъпи информация която му е необходима. Напр. Идва кандидат курсист с въпрос към чатбота - дай ми инф за всички курсове. AI modela няма тази информация, той не е обучаван за това, но вижда че има инструмент и той се обръща към този инструмент. Ние управляваме инструментите. и когато AI модела извика инструмента - ние се обръщаме към external knowledge базата (може да е релационна база или нерелационна база, векторна база или обикновен файл) -> обръщаме се към този external knowledge - извличаме това което е релевантно според целите на инструмента и според изискванията на ai modela и му връщаме отговор който по време на inference, по време на генериране на респонса ние обогатяваме контекста само с тази информация, която AI Modela пожелае. Не фурсираме AI modela да знае всичко, а му даваме възможността той да си потърси необходимата информация

## RAG (Retrieval-Augmented Generation)



### \*\*Fine-Tuning:

като концепция ни дава възможност да вземем базов модел, който е обучаван върху някакъв предварителен огромен dataset(данни), обикновено се обучава върху интернет, книги, репозиторията. Взимаме Предварително натрениран ai model (Pre-trained Base AI Model) и го обоготяваме, дообучаваме на базата на нашият knowledge. Взимаме някакъв LLM и започваме вторичен процес на обучение до external knowledge. И това каквато ще получим от този вторичен процес на дообучаване на модела е един нов ai model: този модел е Fine-Tuned AI Model-вътре в него е вградено цялото познание от което имаме нужда. Взимаме този Fine-Tuned AI Model с който ще осъществим интеракцията с нашият потребител. Концепцията тука е че AI Modela вече има вградени вътре във себе си всички тези допълнителни знания, от които би имал нужда, за да може да отговори на нашият потребител.



## Summary:

|                     | Prompt Engineering                           | CAG                         | RAG                             | Fine-Tuning    |
|---------------------|----------------------------------------------|-----------------------------|---------------------------------|----------------|
| Implementation cost | Lowest                                       | Low                         | Medium                          | Highest        |
| Maintenance cost    | None/Lowest                                  | Low                         | Low                             | Medium-to-High |
| Inference cost      | Lowest                                       | Highest                     | Initially Low<br>But could grow | Low            |
| Update complexity   | Low                                          | Low-to-Medium               | Medium-to-High                  | Highest        |
| Data requirements   | None                                         | Moderate                    | Moderate                        | Highest        |
| Applicability       | Only in combination<br>with other techniques | Small external<br>knowledge | Great                           | Good if...     |